



**INSTITUTO TECNOLÓGICO Y DE ESTUDIOS SUPERIORES  
DE MONTERREY**

***Desarrollo de proyectos de análisis de datos***

**Evidencia 2. Establecimiento de patrones y relaciones y  
correlaciones entre variables**

**Alumno:**

Raúl Alan Mayagoitia      A01563069

**Profesores:**

Jesús Esteban Cienfuegos Zurita

Javier Franco Chacón

Sergio Armando Medina González

**Fecha de entrega:**

11 oct 2023

## Resumen

En esta investigación, se llevará a cabo un minucioso análisis de datos relacionados con el proceso de laminado en la industria del acero, con el objetivo de identificar variables relevantes y emplear métodos apropiados para abordar los valores faltantes. La optimización de este proceso es esencial para garantizar la calidad y la eficiencia en la producción de acero.

Inicialmente, se evaluarán las variables categóricas y numéricas, identificando la cantidad de datos faltantes en cada una de ellas. A lo largo de este análisis, se aplicarán diversos enfoques, como la moda, la mediana, el promedio y la regresión múltiple, con el fin de abordar las lagunas en los datos y mejorar su integridad.

Se considerará la regresión múltiple como una herramienta valiosa, pero se tendrá en cuenta que su utilidad puede depender de la confiabilidad de los resultados, medida a través del coeficiente de determinación  $R^2$ . Cuando la  $R^2$  resulte insatisfactoria, se optará por la mediana como una alternativa confiable, especialmente cuando se observe una distribución en forma de campana de Gauss en los datos. Además, se exploró el uso de una Artificial Neural Network como mejor método con mayor precisión.

Adicionalmente, se llevará a cabo la eliminación de variables que se consideren poco relevantes para el análisis, basándose en criterios como el valor p y la multicolinealidad (VIF).

Palabras clave: Investigación, análisis de datos, laminado, industria del acero, variables relevantes, valores faltantes, optimización del proceso, calidad, eficiencia, variables categóricas, variables numéricas, enfoques, moda, mediana, promedio, regresión múltiple, lagunas en los datos, integridad de los datos, coeficiente de determinación  $R^2$ , distribución en forma de campana de Gauss, Artificial Neural Network, precisión, eliminación de variables, relevancia de variables, valor p, multicolinealidad, VIF (Variance Inflation Factor).

**Instrucciones:**

Entregar un reporte individual basado en los datos obtenidos en el reto, en donde se explique y argumente con palabras propias la forma de cómo realizó el análisis estadístico, como se resolvieron conflictos en la modelación y cómo se llegó a las conclusiones obtenidas.

**Rubrica:**

Expone de forma óptima juicios sobre una situación o problema, derivados de la evaluación integral de la información disponible (supuestos, premisas, conclusiones, puntos de vista, opiniones, hipótesis, razonamientos, procedimientos o métodos, etc.) en la que identifica con precisión aspectos esenciales, falacias, contradicciones y concordancias con los que construye argumentos sólidos para sustentar una postura personal o grupal.

**1. Selecciona el conjunto de variables que ayudarán a construir el primer modelo de regresión y de esta selección define qué variables son independientes y cuáles son dependientes.**

Las variables dependientes son aquellas que dependen de otras variables, en este caso, podemos la variable dependiente es Steel plate yield strength (la cual es el resultado de una serie de procesos químicos y de manufactura para obtener una fuerza en el acero, los datos de esta variable son valores numéricos que oscilan entre 237 y 588), por lo tanto todas las demás variables son variables independientes de Yield Strength.

Aquí el truco está en como hacer para estimar el valor del Yield Strength de la manera más precisa posible, inicialmente cargaremos la base de datos en Minitab, incluyendo las variables categóricas, todo esto no da los siguientes resultados.

**Imagen 1.** Proceso para hacer el modelo de regresión de Steel plate yield strength con todas las variables, tanto numéricas como categóricas. (en Minitab)

Regression

Responses:

'Steel plate yield strength'

Continuous predictors:

'C\_Steel plate thickness ordered' 'C\_Steel plate temperature at ro'-Calcium

Categorical predictors:

'Chemical type code' 'Steel type code' 'Steel purity code' 'Rolling type applied to steel p'  
'Steel plate yield strength disc' 'Steel plate yield strength di\_1'

Model... Options... Coding... Stepwise...  
Validation... Graphs... Results... Storage...

Select

? Reset Cancel OK

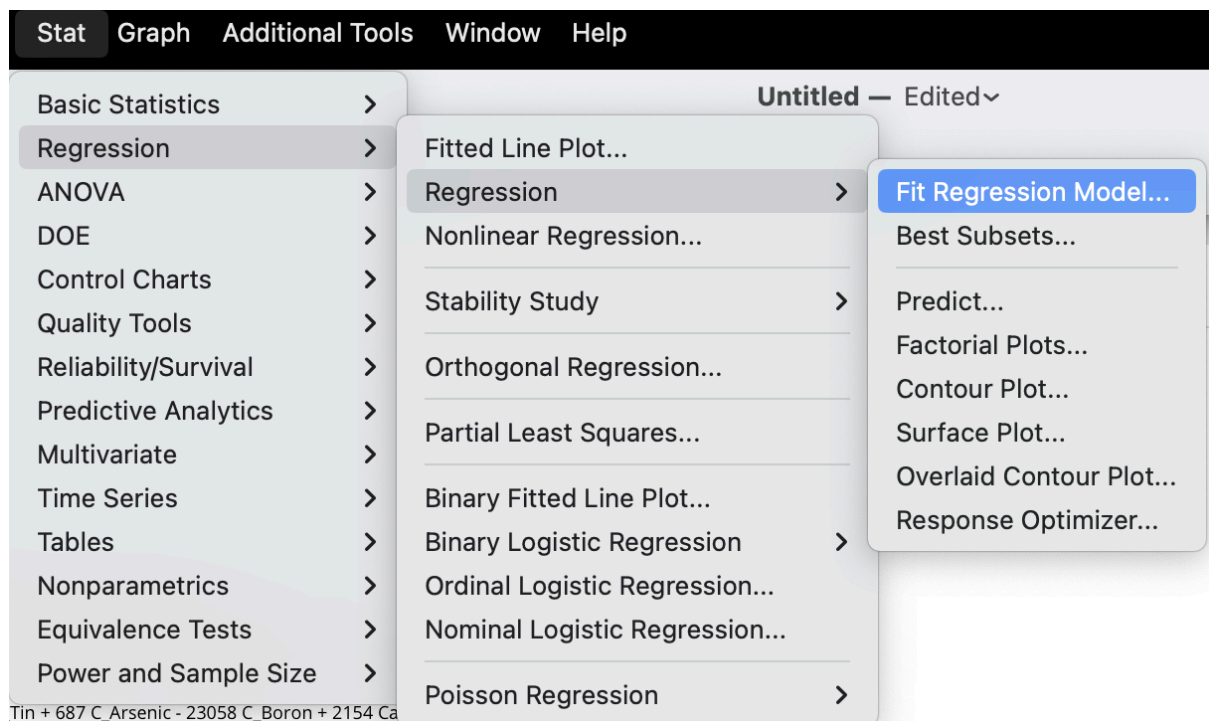
Pasos a seguir para crear el modelo de regresión.

1. Dar clic derecho en el archivo .csv de la base de datos y escoger la opción “Abrir con”  
→ Minitab.
2. Una vez cargado el archivo nos dirigimos a Stats → Regression → Regression (otra vez) → Fit Regression Model
3. Se nos abra la ventana que esta explicita en la parte superior, en cual ignoraremos las columnas de Group 1(RT), Timestamp y Sample ID, (las cuales no son relevantes ni utiles)
4. Seleccionamos la variable respuesta (output) Steel Plate Yield Strenght.
5. Separamos variables numéricas de variables categóricas tal como se muestra en la imagen 1. Damos clic en OK

Al generar el modelo de Regresión se nos abre una ventana la cual tiene muchos datos como:

- Metodo usado
- Ecuacion de Regresion
- Coeficientes de cada una de las variables
- El resumen del modelo generado (La  $r^2$ , la  $r^2$  ajustada y datos adicionales).
- Analisis de la Varianza
- Fits and Diagnostics for Unusual Observations

*Imagen 2. Pasos a seguir para hacer el modelo de regresión lineal.*



Pondremos especial atención en los valores de p-value y los valores de VIF, esto con el objetivo de eliminar de una vez variables que no tienen un rol importante al predecir el Yield Strength.

Estas son las razones por las cuales pondremos atención en estos indicadores:

El valor-P es un indicador usado para decidir si una característica (como el porcentaje de cobre usado al predecir el Yield Strength) afecta o no algo los que en verdad nos importa, (el Yield Strength)

Un valor-P bajo es (menor al 5%) es una buena señal, nos indica que la variable SI tiene un efecto sobre el Yield Strength.

Por el contrario, Un valor-P alto (mayor al 5-10%) es una alerta: nos dice que la característica probablemente no tenga un efecto notable relevante sobre el Yield strength.

En cuanto al VIF:

el VIF es Factor de Inflación de la Varianza (VIF):

El VIF nos dice si algunas variables están diciendo lo mismo. (multicolinealidad)  
Si el VIF es alto, indica que las 2 variables indican lo mismo (como si dos amigos te contaran exactamente la misma historia), por lo tanto, no estamos obteniendo nueva información de la segunda variable y nos podemos quedar con solamente 1.

Un VIF de 1 indica que no hay colinealidad. A medida que el VIF aumenta, aumenta la colinealidad. Como regla general, un VIF mayor que 5-10 indica una multicolinealidad problemática.

***Imagen 3.** Resumen del Modelo antes de hacer cambios (ahorita todas las variables categóricas y numéricas están en juego).*

## Model Summary

<b>S</b>	<b>R-sq</b>	<b>R-sq(adj)</b>	<b>R-sq(pred)</b>
17.4901	92.65%	92.51%	92.26%

**Imagen 4.** Coeficientes del modelo de regresión de Steel plate yield strength con todas las variables, tanto numéricas como categóricas.


### Coefficients

Term	Coef	SE Coef	T-Value	P-Value	VIF
Constant	389.9	20.5	19.04	0.000	
C_Steel plate thickness ordered	-2.0830	0.0900	-23.15	0.000	1.98
C_Steel plate temperature at ro	-0.0131	0.0214	-0.61	0.543	3.24
C_Steel plate temperature after	-0.1323	0.0219	-6.03	0.000	5.19
C_Manganese	56.80	4.89	11.61	0.000	7.35
C_Phosphorus	441	102	4.34	0.000	1.62
C_Sulfur	-1251	212	-5.90	0.000	1.86
C_Carbon	297.2	19.5	15.26	0.000	3.39
C_Silicon	23.26	8.75	2.66	0.008	8.23
C_Aluminium	173.5	63.7	2.72	0.007	1.41
C_Copper	90.9	37.7	2.41	0.016	23.84
C_Niobium	2169.9	53.5	40.59	0.000	4.30
C_Nickel	-70.8	26.9	-2.63	0.009	15.56
C_Chromium	-82.5	20.9	-3.95	0.000	14.28
C_Vanadium	175.8	84.6	2.08	0.038	5.60
C_Molybdenum	169	147	1.14	0.253	5.63
C_Titanium	-118	491	-0.24	0.810	1.84
C_Tin	548	150	3.65	0.000	1.23
C_Arsenic	687	480	1.43	0.153	1.36
C_Boron	-23058	5744	-4.01	0.000	1.33
Calcium	2154	1048	2.06	0.040	1.25
Chemical type code					
II	-5.34	2.57	-2.08	0.038	7.95
III	11.66	3.33	3.50	0.000	18.24
IV	37.30	7.33	5.09	0.000	11.06
VI	44.8	12.1	3.69	0.000	38.84
VIII	-3.5	12.0	-0.29	0.772	1.42
Steel type code					
3	-11.69	2.20	-5.31	0.000	6.95
5	-14.11	7.37	-1.91	0.056	12.17
Steel purity code					
2	-7.00	1.78	-3.92	0.000	5.17
3	-6.37	2.00	-3.18	0.001	4.77
4	13.62	8.62	1.58	0.114	1.21
5	65.3	10.2	6.41	0.000	1.69
7	-0.56	3.65	-0.15	0.878	2.09
8	-11.35	2.26	-5.02	0.000	4.54
Rolling type applied to steel p					
LC	2.41	1.60	1.51	0.132	2.69
TM	20.33	3.57	5.70	0.000	5.39
Steel plate yield strength disc					
LOW	-6.75	2.19	-3.08	0.002	4.93
Steel plate yield strength di_1					
LOW	-31.67	2.76	-11.47	0.000	5.78
MEDIUM	-20.21	1.82	-11.08	0.000	2.50

Al analizar la tabla de coeficientes se notan varias alertas rojas (encerradas en un círculo rojo)


Además, me tome la libertad de realizar una matriz de correlaciones en escala de color para ver si encontraba alguna otra inconsistencia o alerta.

**Imagen 5.** Matriz de Correlaciones de todas las variables. (Nótese una alerta en la línea del C\_Copper) Alertas marcadas con un círculo rojo.





**Imagen 6.** Matriz de Correlaciones de  $C\_Copper$ ,  $C\_Nickel$ ,  $C\_Chromium$ ,  $C\_Niobium$ ,  $C\_Manganese$  y  $C\_Steel\ plate\ thickness\ ordered$ , en donde se puede apreciar con mejor detalle que el Copper está altamente correlacionado con las variables de Nickel y Chromium.



Por esta razón y porque el Copper también tiene el valor más alto de VIF, eliminaremos el  $C\_Copper$ , junto con todas las variables que también tienen un p-value por arriba de los límites de 5%, después volveremos a realizar el modelo de regresión.

Variables eliminadas en esta ronda que no serán tomadas en cuenta:

Group 1(RT), Timestamp y Sample ID, Copper, Steel plate temperature at rolling process, Molybdenum, Titanium, Arsenic.

**Imagen 7.** Coeficientes del modelo de regresión de Steel plate yield strength con las variables que sobrevivieron después de la primer ronda de eliminación.


### Coeficients

Term	Coef	SE Coef	T-Value	P-Value	VIF
Constant	382.8	16.7	22.88	0.000	
C_Steel plate thickness ordered	-2.0508	0.0821	-24.97	0.000	1.63
C_Steel plate temperature after	-0.1381	0.0195	-7.07	0.000	4.07
C_Manganese	54.57	4.82	11.31	0.000	7.07
C_Phosphorus	343.5	99.6	3.45	0.001	1.54
C_Sulfur	-1247	205	-6.10	0.000	1.72
C_Carbon	301.5	18.2	16.52	0.000	2.94
C_Silicon	25.41	8.63	2.94	0.003	7.91
C_Aluminium	187.3	63.5	2.95	0.003	1.38
C_Niobium	2161.0	53.0	40.74	0.000	4.18
C_Nickel	-54.3	26.0	-2.09	0.037	14.34
C_Chromium	-65.3	18.0	-3.63	0.000	10.48
C_Vanadium	202.4	83.4	2.43	0.015	5.38
C_Tin	726	144	5.05	0.000	1.12
Calcium	2073	1045	1.98	0.047	1.23
Chemical type code					
II	-4.61	2.58	-1.79	0.074	7.90
III	13.21	3.30	4.00	0.000	17.78
IV	37.25	7.24	5.15	0.000	10.66
VI	62.73	7.49	8.38	0.000	14.60
VIII	-0.3	12.0	-0.03	0.980	1.39
Steel type code					
3	-10.14	2.17	-4.68	0.000	6.64
5	-16.55	6.20	-2.67	0.008	8.51
Steel purity code					
2	-7.83	1.78	-4.40	0.000	5.07
3	-6.79	2.00	-3.40	0.001	4.69
4	11.90	8.21	1.45	0.147	1.09
5	59.9	10.0	5.97	0.000	1.63
7	-2.81	3.60	-0.78	0.436	2.01
8	-13.70	2.19	-6.26	0.000	4.20
Rolling type applied to steel p					
LC	3.17	1.42	2.24	0.025	2.09
TM	21.13	3.57	5.92	0.000	5.33
Steel plate yield strength disc					
LOW	-6.79	2.20	-3.08	0.002	4.92
Steel plate yield strength di_1					
LOW	-32.19	2.77	-11.62	0.000	5.76
MEDIUM	-20.76	1.83	-11.37	0.000	2.48

Calcium se quedó justo por debajo de ser eliminado, podemos o no decidir si eliminarlo. En este caso decidiremos eliminarlo porque casi llegó al 5%, además, eliminaremos la variable categórica de Chemical type code porque todos sus VIFs son muy altos y la única parte de la variable que no tiene un VIF alto tiene un pvalue de 98%, lo cual es sumamente malo, también eliminaremos la de C\_Nickel y C\_Chromium (si hacemos el modelo sin el Nickel y dejando el Chromium se sigue presentando multicolinealidad y un VIF de 7.53, vease en archivo de minitab), ya que tienen un VIF muy alto y presenta multicolinealidad según la siguiente parte seleccionada de la matriz de correlaciones inicial.

También eliminaremos el Silicon porque su pvalue sube a casi un 8%

**Imagen 8.** Matriz de Correlaciones de C\_Silicon, C\_Nickel, C\_Chromium, C\_Manganese, en donde se puede apreciar con mejor detalle que el Nickel está altamente correlacionado con las variables de Chromium e incluso un poco él con el C\_Silicon.



**2. Selecciona el conjunto de registros que ayudarán a construir el primer modelo de regresión y justifica dicha selección.**

*Imagen 9. Coeficientes del modelo de regresión de Steel plate yield strength con las variables que sobrevivieron después de la primer, segunda, tercera y cuarta ronda de eliminación. (También quitamos el Aluminium porque su pvalue subió a casi 18%)*

### Coeficients

Term	Coef	SE Coef	T-Value	P-Value	VIF
Constant	407.0	17.0	24.00	0.000	
C_Steel plate thickness ordered	-1.9153	0.0832	-23.03	0.000	1.52
C_Steel plate temperature after	-0.1404	0.0201	-6.98	0.000	3.94
C_Phosphorus	208	103	2.02	0.043	1.50
C_Manganese	59.16	3.71	15.96	0.000	3.81
C_Sulfur	-904	212	-4.27	0.000	1.68
C_Carbon	237.1	16.7	14.22	0.000	2.24
C_Niobium	2453.3	43.2	56.76	0.000	2.53
C_Vanadium	528.4	41.5	12.73	0.000	1.22
C_Tin	854	150	5.70	0.000	1.10
C_Boron	-31172	5918	-5.27	0.000	1.28
C_Chromium	-31.9	15.6	-2.04	0.041	7.18
Steel type code					
3	-15.40	1.10	-13.95	0.000	1.57
5	12.27	5.74	2.14	0.033	6.66
Steel purity code					
2	-9.53	1.61	-5.94	0.000	3.77
3	-6.55	1.76	-3.72	0.000	3.34
4	1.90	8.43	0.23	0.821	1.04
5	59.3	10.2	5.80	0.000	1.53
7	-6.68	3.66	-1.83	0.068	1.89
8	-8.72	2.04	-4.28	0.000	3.32
Rolling type applied to steel p					
LC	3.05	1.47	2.08	0.038	2.05
TM	20.45	3.72	5.50	0.000	5.28
Steel plate yield strength disc					
LOW	-8.06	2.30	-3.50	0.000	4.89
Steel plate yield strength di_1					
LOW	-38.79	2.78	-13.96	0.000	5.28
MEDIUM	-26.53	1.80	-14.78	0.000	2.19

En la imagen 9, es crucial resaltar que los valores en las columnas de Valor-P y Factor de Inflación de la Varianza están dentro de sus rangos aceptables. Este hecho es de gran importancia, ya que confirma que las variables seleccionadas para el modelo mantienen una relación estadísticamente relevante con la variable dependiente.

Gracias a esta adecuada selección y comportamiento de las variables, el modelo ha logrado un nivel de confianza del 91.70% en la predicción de la resistencia de rendimiento, como se muestra en la imagen 10.

*Imagen 10. Resumen del Modelo después de hacer los cambios.*

## Model Summary

S	R-sq	R-sq(adj)	R-sq(pred)
18.4174	91.80%	91.70%	91.53%

3. Construye el primer modelo matemático e identifica las variables potencialmente significativas.

*Imagen 11. Modelo matemático final en Minitab*

### Regression Equation

Steel plate yield strength = 407.0 - 1.9153 C\_Steel plate thickness ordered  
 - 0.1404 C\_Steel plate temperature after + 208 C\_Phosphorus  
 + 59.16 C\_Manganese - 904 C\_Sulfur + 237.1 C\_Carbon  
 + 2453.3 C\_Niobium + 528.4 C\_Vanadium + 854 C\_Tin  
 - 31172 C\_Boron - 31.9 C\_Chromium + 0.0 Steel type code\_1  
 - 15.40 Steel type code\_3 + 12.27 Steel type code\_5  
 + 0.0 Steel purity code\_1 - 9.53 Steel purity code\_2  
 - 6.55 Steel purity code\_3 + 1.90 Steel purity code\_4  
 + 59.3 Steel purity code\_5 - 6.68 Steel purity code\_7  
 - 8.72 Steel purity code\_8  
 + 0.0 Rolling type applied to steel p\_BL  
 + 3.05 Rolling type applied to steel p\_LC  
 + 20.45 Rolling type applied to steel p\_TM  
 + 0.0 Steel plate yield strength disc\_HIGH  
 - 8.06 Steel plate yield strength disc\_LOW  
 + 0.0 Steel plate yield strength di\_1\_HIGH  
 - 38.79 Steel plate yield strength di\_1\_LOW  
 - 26.53 Steel plate yield strength di\_1\_MEDIUM

Esta  $r^2$  tan alta, también se debe a la superioridad con la que se trabajó mi base de datos inicial, en donde para cada una de las variables genere una Artificial Neural Network, la cual es reconocida por una precisión sumamente exacta, además, al realizar una ANN para la variable de Yield Strength en DataMaestro, podemos tener un modelo el cual tenga una  $r^2$  superior como se muestra en la imagen 12.

La ecuación sugiere que el "Steel plate yield strength" es una combinación de muchos factores. El término constante, 407.0, es el valor base del "Steel plate yield strength" cuando todas las otras variables son cero. En otras palabras, en ausencia de todos los otros factores, el "Steel plate yield strength" es 407. (hay factores que afectan negativamente al Yield Strength por eso en la base de datos el valor mínimo que encontramos fue de 237, un promedio de 390 y un máximo de 588 mPa)

Los coeficientes numéricos junto a cada variable indican cómo un cambio en esa variable afecta al "Steel plate yield strength", asumiendo que todas las demás variables se mantienen constantes:

Por cada unidad en milímetros que aumenta "Steel plate thickness ordered", el "Steel plate yield strength" disminuye en 1.9153 unidades.

Un aumento en "Steel plate temperature after spray cooling process" lleva a una disminución de 0.1404 mPa unidades en el "Steel plate yield strength". (tal vez indica que la placa de acero no tuvo un perfecto enfriamiento)

Por cada unidad que aumenta "Phosphorus", el "Steel plate yield strength" aumenta en 208 unidades. (estos son valores muy pequeños porque lo mínimo que usamos de P fue 0.006 y lo máximo un 0.08).

De manera similar, un aumento en "C\_Manganese" lleva a un aumento de 59.16 unidades en el "Steel plate yield strength".

Un incremento en "C\_Sulfur" resulta en una disminución de 904 unidades en el "Steel plate yield strength". Por lo cual afecta negativamente

... Y así sucesivamente para cada variable en la ecuación.

Los coeficientes con un valor de 0.0, como "Steel type code\_1" y "Steel purity code\_1", sugieren que estas variables no tienen ningún efecto importante sobre el "Steel plate yield strength" en este modelo.

Y podemos considerar el ignorarlas.

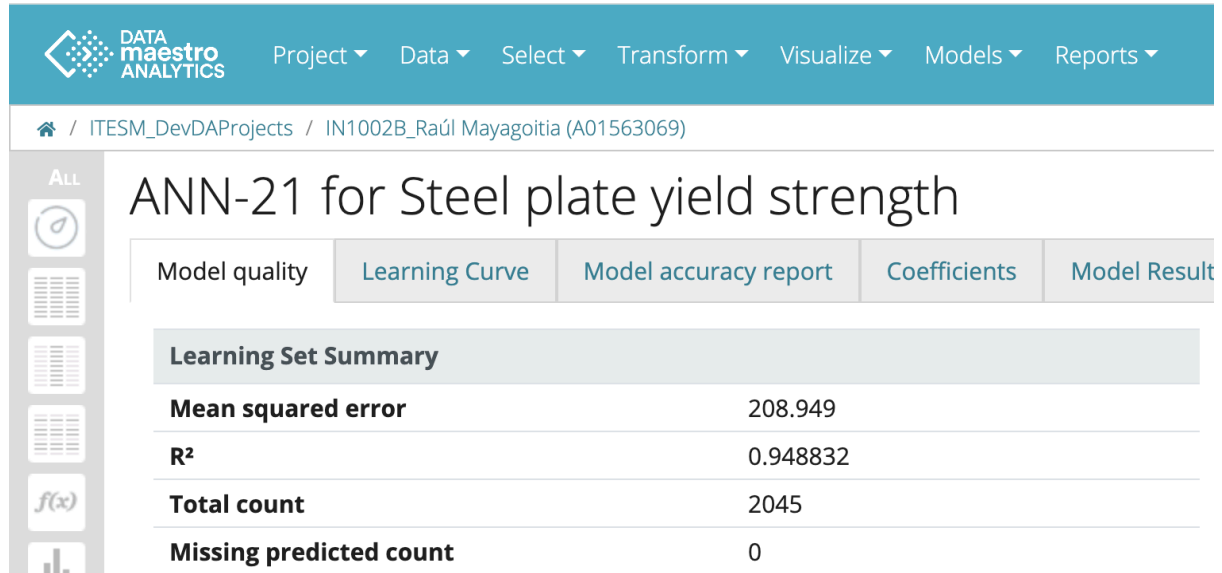
Las redes neuronales artificiales (ANN, por sus siglas en inglés) pertenecen a la categoría de aprendizaje supervisado. Estas redes crean conexiones aleatorias entre variables y evalúan las correlaciones entre ellas.

A menudo, las ANN se consideran como "métodos de caja negra" porque, aunque son potentes y pueden modelar relaciones complejas, su funcionamiento interno y sus decisiones son difíciles de interpretar.

En esencia, un método de "caja negra" es aquel en el que puedes ver las entradas y las salidas, pero no necesariamente comprendes o visualizas claramente cómo se procesa la información en el interior.

Esto hace que las ANN, a pesar de su eficacia, presenten desafíos en cuanto a su interpretación.

*Imagen 12. ANN creado por DataMaestro, después de hacer una interpolación de la base de datos usando un total de 21 ANNs para cada una de las variables en donde teníamos valores faltantes.*



*Imagen 13. Como funciona un ANN creado por DataMaestro, curso en línea*

**Artificial Neural Network introduction**

**Definition:**

- Artificial Neural Network (ANN) technique is a supervised learning method used for regression or classification tasks.
- Its main objective is to build predictive models (more usually for non-linear regression problems even if classification problems can also be dealt with).

**Method principles:**

- An ANN can be seen as a complex system consisting of multiple simple units (neurons) organized in different layers (input layer, hidden layer(s) and output layer).
- Units are inter-connected (feed forward structure), the output of each neuron is computed by some non-linear function of the sum of its inputs and each connection is weighted by a numerical parameter.
- The goal of the building algorithm is to minimize the prediction error, where the error is a function of the weights attached to each connection. At each iteration, the weights are adjusted to reduce the prediction error.
- Inputs: Numerical only
- Outputs: Numerical or Symbolic

**Main advantages:**

- Very good accuracy (probably the best technique in that regard)
- Universal approximation capability (even for highly non-linear functions)

**Main disadvantages:**

- Input variables must be numerical
- Very poor interpretability ("black box" behavior)
- High computational cost during the training stage (restricted number of input variables)

**Diagram and Formulas:**

The diagram shows a feedforward neural network with an Input Layer (nodes  $x_1, x_2$ ), a Hidden Layer (nodes  $h_1, h_2$ ), and an Output Layer (node  $o_1$ ). Weights are indicated on the connections:  $x_1 \rightarrow h_1$  is  $w_{1,1}$ ,  $x_1 \rightarrow h_2$  is  $w_{1,2}$ ,  $x_2 \rightarrow h_1$  is  $w_{2,1}$ , and  $x_2 \rightarrow h_2$  is  $w_{2,2}$ . The output node  $o_1$  receives inputs from  $h_1$  and  $h_2$  with weights  $w_{2,1}$  and  $w_{2,2}$ .

Sum weighted inputs:  $z = \sum_{i=1}^n (x_i \cdot w_i) + c$

Activation Function:  $h(z) = f(z) = \frac{1}{1 + e^{-z}}$


Output:  $O_1 = f(h_1 \cdot w_{2,1} + h_2 \cdot w_{2,2} + c)$

Where  $c$  is the independent (bias term)

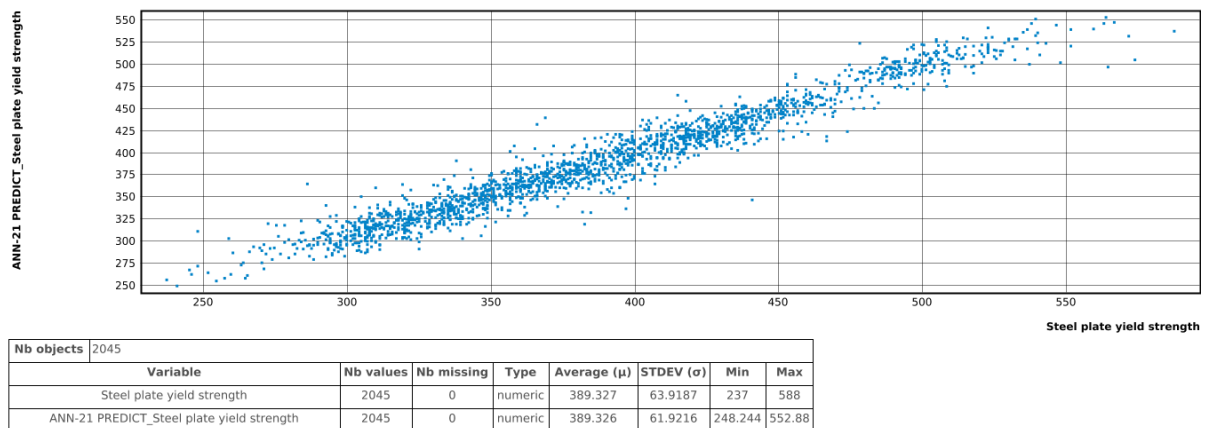
Using a sigmoid activation function



**Imagen 14.** Línea de tendencia del ANN\_Predict con respecto al Yield Strength creado por DataMaestro, después de hacer una interpolación de la base de datos usando un total de 21 ANNs para cada una de las variables en donde teníamos valores faltantes.





**Imagen 15.** Scatter Plot que muestra a línea de tendencia que sigue el ANN\_Predict con respecto al Yield Strength creado por DataMaestro.



Por último, anexo todos los archivos que use para hacer esta evidencia:

- [Base de Datos RT3](#)
- [Evidencia 2.mpx](#)
- [Yield Strength - All Filled \(A, t & #\) \(1\).csv](#)

-  DATAmestro Analytics\_ Artificial Neural Network.pdf
- Video de Youtube que ayuda a entender como funciona una ANN
  -  Training an unbeatable AI in Trackmania

Referencia:

(2023). 360learning.com.

<https://pepite.360learning.com/course/play/6099414231aaa03aece6ac9b>